VERİ MADENCİLİĞİ VE İŞ ZEKASI

Vize Projesi Dokümantasyonu

Finansal Haber Metinleri ve Piyasa Eğilimi Modellemesi

FinBERT ile haber duygu analizi, hisse getirisi regresyonu ve interaktif iş zekası paneli (AAPL, MSFT, NVDA, TSLA, 2025)

Proje ekibi: Gizem Doğan – 95240148
Zamıra Babahanova – 95230102
Zeynep Karakaya – 95230042
Begench Rejepov – 95230197
Sultanbek Kazakov - 95230117

Öğr. Gör. MUSTAFA ÇAĞIN ARSLAN
Bölüm / Üniversite: Yönetim Bilişim Sistemleri/ İstanbul Medipol Üniversitesi
Tarih: 8 Kasım 2026

İçindekiler

1. Analiz Raporu
- **1.1 Problem Tanımı**
- **1.2 Sektörel Motivasyon**
- **1.3 Önerilen Uçtan Uca Çözüm**
- **1.4 Varsayımlar ve Sınırlılıklar**

2. Müşteri (Paydaş) Gereksinimleri Raporu

3. Sistem Gereksinimleri
- **3.1 Fonksiyonel Gereksinimler (FR)**
- **3.2 Fonksiyonel Olmayan Gereksinimler (NFR)**

Use Case senaryoları ve diyagramları, kabul kriterleri ve test senaryoları ayrı Excel dosyasında sunulacaktır.

4. Gerçek Analiz Bulguları ve Değerlendirme
- **4.1 Veri setinin kapsamı**
- **4.2 Regresyon sonuçları**
- **4.3 Bulguların yorumlanması**
- **4.4 Ertesi gün getirisiyle korelasyon**
- **4.5 Regresyon grafiği**
- **4.6 Sonuç ve sonraki çalışmalar**

1. Analiz Raporu

1.1 Problem Tanımı

Finansal piyasalarda fiyatlar yalnızca geçmiş fiyat hareketlerinden değil, yatırımcıların yeni bilgiye verdiği tepkiden de etkilenir. Haber akışı bu bilginin başlıca kaynaklarındandır. Günlük yüzlerce haber başlığı insan analistler tarafından manuel okunamaz, öznel yorumlanır ve ölçülebilir bir göstergeye dönüştürülemez. Bu çalışmanın problemi şudur:

> **Problem:** Yapılandırılmamış (metinsel) finansal haber verisinden nicel bir duygu göstergesi üretmek ve bu göstergenin dört teknoloji hissesinin (AAPL, MSFT, NVDA, TSLA) 2025 yılı günlük getirisi ile ilişkisini hisse bazında ve birleşik olarak istatistiksel biçimde sınamak.

1.2 Sektörel Motivasyon

- **Davranışsal finans:** Yatırımcı duyarlılığının kısa vadeli fiyat hareketlerini etkileyebildiği literatürde tartışılmaktadır (ör. Tetlock, 2007).
- **Alternatif veri:** Metin verisi, geleneksel fiyat verisini tamamlayan alternatif veri sınıfı olarak yaygınlaşmıştır.
- **Alana özel dil modelleri:** Genel amaçlı duygu sözlükleri finans jargonunu (“beats estimates”, “downgrade”) yanlış sınıflandırabilir. FinBERT, finansal metinler üzerinde ince ayar yapılmış bir BERT modeli olduğundan bu alanda daha uygundur.
- **Karşılaştırmalı analiz ihtiyacı:** Duygu–getiri ilişkisinin hisseler arasında farklılaşıp farklılaşmadığı karar desteği açısından önemlidir.
- **İş zekası ihtiyacı:** Çıktıların karar vericilere interaktif ve izlenebilir biçimde sunulması gerekir.

1.3 Önerilen Uçtan Uca Çözüm

Çözüm, yalnızca CSV dosyalarıyla haberleşen dört modüllü bir veri hattıdır. Tüm dosyalar Ticker sütunu taşır.

Modül	Script	Girdi	Çıktı
1. Veri toplama	01_market_data.py	Yahoo Finance (yfinance)	data/market_data.csv
2. Duygu analizi	02_sentiment_analysis.py	data/news_headlines.csv (varsa) veya market_data.csv işlem günlerinden üretilen kurgusal başlıklar	data/news_sentiment.csv

Modül	Script	Girdi	Çıktı
3. Modelleme	03_regression_model.py	market_data.csv, news_sentiment.csv	merged_dataset.csv regression_summary.csv ols_summary.txt regression_plot.png
4. Sunum	app.py (Streamlit + Plotly)	Yukarıdaki CSV dosyaları	İnteraktif karar destek paneli

Yöntem özeti:

1. Her hisse için Daily_Return = Close_t / Close_(t-1) − 1 hesaplanır (düzeltilmiş kapanış fiyatı, dönem: 01.01.2025 – 31.12.2025).
2. Her başlık için FinBERT sınıf olasılıkları alınır ve Sentiment_Score = P(pozitif) − P(negatif) ∈ [−1, +1] türetilir.
3. Aynı hisse ve güne ait başlıkların skoru günlük ortalamaya indirgenir, (Date, Ticker) anahtarıyla inner-join yapılır.
4. Daily_Return = $\beta_0 + \beta_1 \cdot$Sentiment_Score + ε modeli her hisse için ve tüm hisseler birleşik olarak Scikit-learn ve Statsmodels OLS ile tahmin edilir.
5. Sonuçlar normalize fiyat trendi, duygu endeksi, regresyon grafikleri, hisse karşılaştırma tablosu ve ham veri ile panoda sunulur.

1.4 Varsayımlar ve Sınırlılıklar

- **Başlıklar kurgusaldır.** Örnek başlıklar, 30 şablonun hisse adıyla ve hisseye özgü kaydırmayla (rotasyon) üretilmesiyle oluşur ve her 2. işlem gününe bir başlık düşer (yaklaşık 125 gün × 4 hisse ≈ 500 başlık). Başlıklar gerçek getirilerden bağımsız üretildiği için β_1'in sıfırdan anlamlı farklı çıkması beklenmez. Çıktılar yöntemin gösterimidir, finansal bulgu değildir. Gerçek haber verisi news_headlines.csv ile sisteme eklenebilir.
- **Zamanlama (look-ahead) riski:** Aynı gün duygu ile aynı gün getiri arasındaki ilişki nedensellik değil, birlikte hareketi gösterir. Haber yayın saati ile piyasa kapanışı arasındaki sıra belirsizdir. Bu nedenle ertesi gün getirisiyle korelasyon ek kontrol olarak raporlanır.
- **Model basitliği:** Tek değişkenli model piyasa, sektör ve makro etkileri kontrol etmez. Düşük R^2 finansal getiri verisinde beklenen bir durumdur.

- **Gözlemlerin bağımsızlığı:** Teknoloji hisseleri aynı piyasa şoklarından birlikte etkilenir, dolayısıyla hisseler arası gözlemler bağımsız değildir. Birleşik (pooled) model hisse sabit etkisi (fixed effects) içermez.
- **Çoklu test sorunu:** Beş regresyon (4 hisse + 1 birleşik) yürütüldüğünden, tek bir p-değerinin 0.05'in altında çıkması tek başına güçlü kanıt sayılmamalıdır.
- **Veri aralığı:** yfinance bitiş tarihini dışarıda bıraktığı için son gözlem 30.12.2025'tir. İlk işlem gününün getirisi hesaplanamadığından analiz dışı kalır.
- **Taşınabilirlik:** Proje klasörünün yolunda Kiril/Türkçe gibi ASCII dışı karakterler bulunursa yfinance'in ağ kütüphanesi sertifika dosyasına erişemeyip veri indirme başarısız olabilir. Proje ASCII bir yolda (ör. C:\apppy) çalıştırılmalıdır.

2. Müşteri (Paydaş) Gereksinimleri Raporu

Aşağıdaki tablo, sistemin paydaşlarını, her birinin beklentilerini ve bu beklentilerin sistemdeki karşılıklarını özetler.

Paydaş	Beklentiler	Sistemden Karşılığı
Bireysel Yatırımcı	Birden fazla hissenin haber tonunu tek ekranda karşılaştırmak; sade görsel arayüz; teknik bilgi gerektirmeyen yorum	Hisse çoklu seçimi, normalize fiyat grafiği, hisse bazında ortalama duygu, etiket dağılımı
Finansal Analist	Duygu–getiri ilişkisinin hisse bazında ve birleşik istatistiksel kanıtı (β, p, R^2); ham veriye erişim; yeniden üretilebilirlik	Hisse bazlı OLS, pooled OLS, karşılaştırma tablosu, regression_summary.csv, CSV dışa aktarma, modüler scriptler
Risk Yöneticisi	Hisse bazında aşırı negatif duygu günlerinin tespiti; modelin sınırlılıklarının şeffaf belirtilmesi; veri kalitesi göstergeleri	Negatif duygu eşiği filtresi, hisse bazında eşleşme oranı, istatistiksel anlamlılık uyarıları
Veri Mühendisi (Operatör)	Yeni hisse ekleme kolaylığı; hata durumunda anlaşılır mesajlar; tek hissenin hatası tüm hattı durdurmamalı	TICKERS / COMPANY_NAMES yapılandırması, hisse bazlı hata yönetimi, [INFO] / [UYARI] / [HATA] mesajları
Ders Sorumlusu / Değerlendirici	Metodolojik tutarlılık, izlenebilirlik, çalışan kod, ölçülebilir kabul kriterleri	Bu doküman, kabul kriterleri, test senaryoları

3. Sistem Gereksinimleri

3.1 Fonksiyonel Gereksinimler (FR)

ID	Modül	Gereksinim
FR-01	Veri Çekme	Sistem, yapılandırılabilir hisse listesi (TICKERS) ve tarih aralığı (varsayılan 01.01.2025 – 31.12.2025) için yfinance ile düzeltilmiş günlük kapanış fiyatlarını indirmelidir.
FR-02	Veri Çekme	Sistem, her hisse için ayrı olarak Daily_Return = (Close_t / Close_(t-1)) − 1 hesaplamalı ve getirisi hesaplanamayan ilk satırı çıkarmalıdır.
FR-03	Veri Çekme	Sistem, tüm hisseleri Date, Ticker, Close, Daily_Return sütunlarıyla tek bir data/market_data.csv dosyasına kaydetmelidir.
FR-04	Veri Çekme	Bir hisse indirilemezse uyarı verip diğerleriyle devam etmelidir. Hiçbiri indirilemezse sıfır olmayan çıkış kodu vermelidir.
FR-05	Duygu Analizi	Sistem, başlıkları ProsusAI/finbert modeliyle sınıflandırmalıdır.
FR-06	Duygu Analizi	Sistem, Sentiment_Score = P(pos) − P(neg) değerini [−1, +1] aralığında üretmelidir.
FR-07	Duygu Analizi	Sistem, her başlık için duygu etiketi (positive / negative / neutral) ve üç sınıfın olasılıklarını (P_Positive, P_Negative, P_Neutral) kaydetmelidir.
FR-08	Duygu Analizi	Sistem, varsa harici data/news_headlines.csv (Date, Ticker, Headline) dosyasını, yoksa kurgusal örnek başlıkları kullanmalıdır. Ticker sütunu yoksa uyarı verip AAPL varsaymalıdır.
FR-09	Duygu Analizi	Örnek başlık tarihleri market_data.csv içindeki işlem günlerinden (her SAMPLE_STEP. gün) üretilmelidir. Piyasa dosyası yoksa yapılandırılan aralıktaki hafta içi günler kullanılmalıdır.
FR-10	Birleştirme	Sistem, aynı hisse ve güne ait birden fazla başlığı günlük ortalama skora indirgemelidir.
FR-11	Birleştirme	Sistem, (Date, Ticker) anahtarıyla inner-join yapmalı ve hisse bazında eşleşme oranını raporlamalıdır.
FR-12	Birleştirme	Sistem, hisse bazında ertesi gün getirisini hesaplayıp skor ile ertesi gün getirisi arasındaki korelasyonu raporlamalıdır.
FR-13	Regresyon	Sistem, her hisse ve tüm hisseler birleşik (pooled) için Scikit-learn LinearRegression ile β_0, β_1, R^2, MSE ve MAE hesaplamalıdır.
FR-14	Regresyon	Sistem, aynı gruplar için Statsmodels OLS özet tablosunu (katsayı, std. hata, t, p, güven aralığı, F) basmalıdır.
FR-15	Regresyon	Gözlem sayısı 3'ten az olan hisseler uyarıyla atlanmalı, hiçbir grup yeterli değilse sistem hata vermelidir.

ID	Modül	Gereksinim
FR-16	Regresyon	Sistem, metrikleri outputs/regression_summary.csv, OLS özetlerini outputs/ols_summary.txt, birleşik veriyi data/merged_dataset.csv olarak kaydetmelidir.
FR-17	Regresyon	Sistem, her grubun saçılım grafiğini ve regresyon doğrusunu tek bir outputs/regression_plot.png dosyasında kaydetmelidir.
FR-18	Pano	Pano, hisse çoklu seçimi, tarih aralığı ve negatif duygu eşiği filtreleri sunmalı ve tüm bölümleri seçime göre güncellemelidir.
FR-19	Pano	Pano, normalize (başlangıç = 100) fiyat trendini interaktif grafikle ve hisse bazında ilk/son kapanış ile yüzde değişim tablosunu göstermelidir.
FR-20	Pano	Pano, hisse bazında günlük duygu endeksini, ortalama duyguyu, etiket dağılımını ve risk eşiği altındaki günleri göstermelidir.
FR-21	Pano	Pano, kapsamı seçilebilen (tek hisse veya birleşik) regresyon grafiğini, $\beta_1/R^2/p/n$ metriklerini, anlamlılık uyarısını ve hisse bazında karşılaştırma tablosunu göstermelidir.
FR-22	Pano	Pano, ham birleşik veri ve haber bazında skor tablolarını göstermeli, birleşik veriyi CSV olarak indirmeye izin vermelidir.

3.2 Fonksiyonel Olmayan Gereksinimler (NFR)

ID	Kategori	Gereksinim
NFR-01	Performans	4 hisse için 1 yıllık günlük veri indirme ve getiri hesabı, normal ağ koşullarında 60 saniyeden kısa sürmelidir.
NFR-02	Performans	Model yüklendikten sonra FinBERT çıkarımı CPU üzerinde yaklaşık 500 başlık için 10 dakikadan kısa sürmelidir.
NFR-03	Performans	03 scripti, 4 hisse ve yaklaşık 1000 piyasa satırı için 30 saniyeden kısa sürede tamamlanmalıdır.
NFR-04	Performans	Pano, ilk yüklemeden sonra filtre değişikliklerine 2 saniyeden kısa sürede yanıt vermelidir (st.cache_data).
NFR-05	Modülerlik	Her aşama bağımsız çalıştırılabilir script olmalı, aşamalar yalnızca CSV dosyalarıyla haberleşmelidir.
NFR-06	Genişletilebilirlik	Yeni hisse eklemek yalnızca TICKERS ve COMPANY_NAMES sabitlerinin güncellenmesiyle mümkün olmalıdır.
NFR-07	Doğruluk	Skor aralığı [−1, +1] dışına çıkmamalı, getiri hesabı bağımsız hesapla ±1e-9 uyuşmalıdır.
NFR-08	Doğruluk	Scikit-learn ve Statsmodels eğim katsayıları her grup için ±1e-8 toleransla aynı olmalıdır.
NFR-09	Doğruluk	Eksik/NaN veri sessizce yutulmamalı, atılan satır sayısı raporlanmalıdır.

ID	Kategori	Gereksinim
NFR-10	Kullanılabilirlik	Pano Türkçe etiketler kullanmalı, her grafikte başlık ve eksen açıklaması bulunmalıdır.
NFR-11	Kullanılabilirlik	Girdi dosyaları yoksa sistem anlaşılır hata mesajı ve çalıştırma sırası önerisi vermelidir.
NFR-12	Dayanıklılık	Tek bir hissenin hatası (indirme, yetersiz gözlem) tüm hattı durdurmamalıdır.
NFR-13	Taşınabilirlik	Sistem Windows/macOS/Linux üzerinde Python 3.10+ ile çalışmalıdır. Proje yolu ASCII karakterlerden oluşmalıdır.
NFR-14	Yeniden Üretilebilirlik	Bağımlılıklar requirements.txt ile tanımlanmalı, aynı girdiyle aynı çıktı üretilmelidir (örnek başlık üretimi deterministiktir).

Use Case senaryoları ve diyagramları, kabul kriterleri ve test senaryoları ayrı Excel dosyasında sunulacaktır.

4. Gerçek Analiz Bulguları ve Değerlendirme

Bu bölüm, proje kodlarının ürettiği data ve outputs klasörlerindeki gerçek CSV ve grafik çıktılarından hazırlanmıştır. Önceki bölümlerde tanımlanan yöntem ve gereksinimler korunmuştur.

4.1 Veri setinin kapsamı

Piyasa veri dosyasında 992 satır, haber duygu analizi dosyasında 496 başlık ve regresyon için birleştirilmiş veri dosyasında 496 gözlem bulunmaktadır. Analiz AAPL, MSFT, NVDA ve TSLA hisselerini kapsamaktadır. Haber başlıkları, harici gerçek haber dosyası bulunmadığı için program tarafından kurgusal örnekler olarak üretilmiştir; piyasa fiyatları ise Yahoo Finance üzerinden elde edilmiştir.

4.2 Regresyon sonuçları

Aşağıdaki tablo outputs/regression_summary.csv dosyasındaki değerleri göstermektedir. R^2 modelin açıklama gücünü, p-değeri ise duygu skoru katsayısının sıfırdan farklı olup olmadığına ilişkin istatistiksel testi ifade eder.

Grup	n	Eğim (β_1)	R^2	MSE	MAE	p-değeri
AAPL	124	-0.001614	0.005277	0.000334	0.012978	0.422662
MSFT	124	-0.002197	0.017448	0.000190	0.009505	0.143625
NVDA	124	0.005043	0.019835	0.000917	0.021461	0.118711
TSLA	124	-0.000692	0.000261	0.001327	0.027682	0.858655
TÜMÜ (pooled)	496	0.000168	0.000029	0.000699	0.017978	0.905316

Kaynak: outputs/regression_summary.csv (projenin çalıştırılmasıyla üretilen çıktı).

4.3 Bulguların yorumlanması

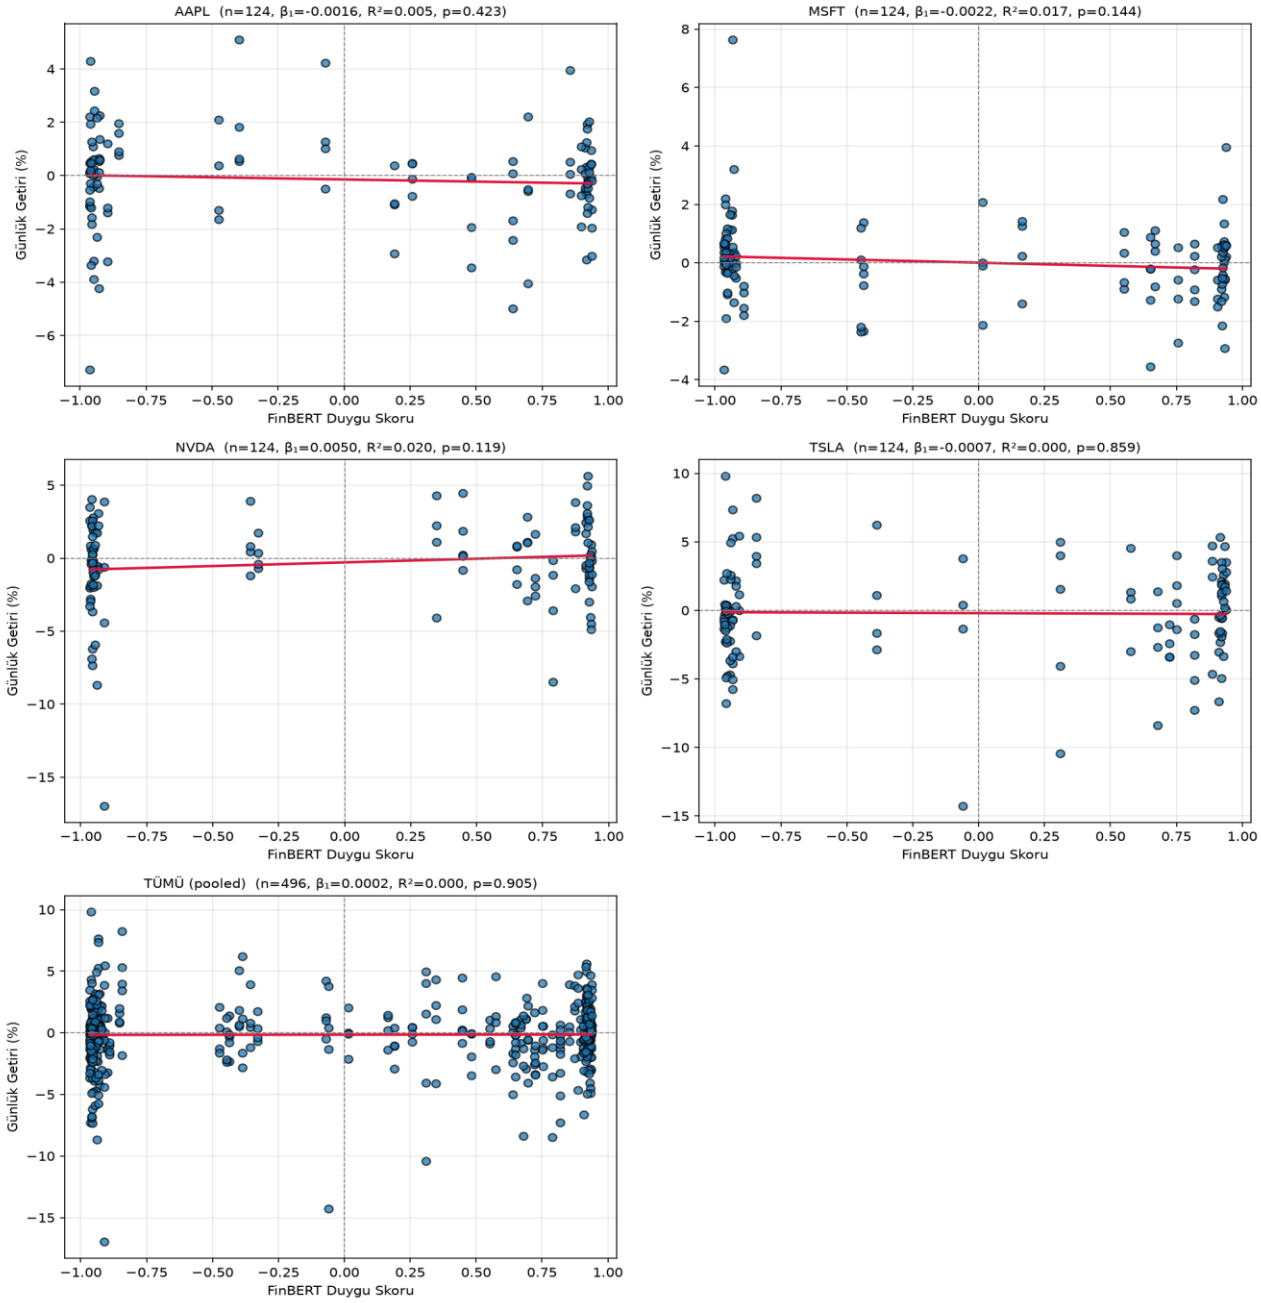
AAPL için R^2 = %0,53 ve p = 0,423; MSFT için R^2 = %1,74 ve p = 0,144; NVDA için R^2 = %1,98 ve p = 0,119; TSLA için R^2 = %0,03 ve p = 0,859 bulunmuştur. Birleşik modelde R^2 yaklaşık %0,003 ve p = 0,905'tir. Beş modelin hiçbirinde $p < 0,05$ koşulu sağlanmamaktadır. Dolayısıyla mevcut örneklemde haber duygu skorunun aynı gün hisse getirisini istatistiksel olarak anlamlı biçimde açıkladığı söylenemez.

Bu sonuç, sistemin başarısız olduğu anlamına gelmez: projenin amacı duygu analizi ve regresyon iş akışını kurup sonuçları şeffaf biçimde raporlamaktır. Kurgusal haber başlıkları gerçek piyasa haber akışını temsil etmediğinden, bulgular finansal piyasalara genellenemez ve yatırım tavsiyesi olarak kullanılmamalıdır.

4.4 Ertesi gün getirisiyle korelasyon

Haber duygu skoru ile ertesi gün getirisi arasındaki raporlanan korelasyonlar AAPL −0,019; MSFT −0,013; NVDA −0,006; TSLA +0,026 ve birleşik veri için +0,004 düzeyindedir. Tüm değerler sıfıra çok yakındır; bu çıktı da güçlü bir doğrusal ilişki göstermemektedir.

4.5 Regresyon grafiği



Şekil 1. Hisse bazında ve birleşik veri üzerinde duygu skoru–günlük getiri saçılım grafikleri ve regresyon doğruları. Kaynak: outputs/regression_plot.png.

4.6 Sonuç ve sonraki çalışmalar

Çalışma, finansal metinleri FinBERT ile sayısallaştıran, fiyat verileriyle birleştiren, hisse bazlı ve birleşik regresyon modelleri kuran ve sonuçları görselleştiren bir iş zekâsı prototipi sunmaktadır. Daha güçlü çıkarımlar için zaman damgalı gerçek haber veri seti, haber yayımlanma saati kontrolü, gecikmeli değişkenler, piyasa faktörleri ve dönem dışı doğrulama önerilir.